

در این قسمت از تمرین به بررسی لیبل‌ها با کمک برنامه لیبل استودیو پرداختیم ابتدا دو انونتیتور آن را به صورت غیر لوکال و در سایت داده ها را به صورت دستی لیبل گذاری کرده و سپس نفر سوم به بررسی این لیبل گذاری ها و اصلاح داده ها با توجه به رویکرد گروه پرداخت. رویکرد گروه ما در این تمرین به صورت زیر بود:

داده هایی که از لحاظ جنسیت مشکل داشت.

داده هایی که از لحاظ اطلاعات، اطلاعات بسیار اندکی داشتند.


داده هایی که تاریخ های مربوط به آن ها نادرست بیان شده بود.

افرادی که دو نام داشتند و دو ردیف را اشغال کرده بودند.

و ...

رویکرد ما بر این گونه بود که مواردی که ویژگی فوق را دارند رویکرد صفر (به معنی نیاز مند به تغییرات) و موارد دیگر برچسب 1 (به معنای کامل) را بخورند.

تصویر زیر از برنامه لیبل استودیو و نشانگر لیبل زن هر سه نفر ماست. که دو نفر در نقش لیبل زننده و نفر دیگر در نقش نفر سوم است.



با توجه به این موارد به بررسی معیار کاپا می پردازیم:

لازم به ذکر است ما در ابتدا 308 ردیف داشتیم و بعد از لیبل گذاری و ویرایش به 300 داده رسیدیم.

برای جدول داریم:

Need Review	Correct	
9	283	Correct
13	3	Need Review

انیتور A که ردیف بالا است به 22 تا داده نیازمند به تغییرات داده است و به 286 داده برچسب درست داده است.

احتمال اینکه به کسی درست بگوید برابر است با، $0.92857142857 = 286/308$

احتمال اینکه نیاز مند به تغییرات اعلام کند

$0.0714285714 = 22/308$

همچنین انیتور B به 16 داده برچسب نیاز مند تغییرات داده و به 292 داده برچسب صحیح داده است. همین مقدار برای B برابر است با

$0.94805194805 = 292/308$

احتمال اینکه نیازمند به تغییرات اعلام کند $0.0519480519 = 16/308$

بنابراین احتمال اینکه با هم درست بگویند برابر است با

$$0.92857142857 * 0.94805194805 = 0.88033395175$$

احتمال اینکه با هم برای داده ای آن را نیازمند به تغییرات بررسی کنند برابر است با

$$0.0714285714 * 0.0519480519 = 0.00371057513$$

از اینرو داریم:

$$pr(e) = 0.00371057513 + 0.88033395175 = 0.88404452688$$

از طرف دیگر توجه شود 283 مورد توسط هر دو تایید و 13 مورد توسط هر دو رد شده است، داریم:

$$pr(a) = (283 + 13)/308 = 0.961038961$$

با توجه به جدول بالا معیار کاپا برای ما برابر است با

$$K = pr(a) - pr(e) / (1 - pr(e)) = 0.664$$

پس ضریب کاپا را به دست آوردیم.

در مرحله بعد از لیبل گذاری با اصلاح داده هایی که نیاز به تغییرات داشت به 300 ردیف داده اصلاح شده رسیدیم.

در قسمت بعد برای قسمت گزارش آماری به تعداد کلمات به ازای هر داده جیسون خود پرداختیم که به تعداد 98 رسیدیم. تعداد رکورد هایی که جمع کردیم بعد از اصلاحات به 300 داده رسید. طول میانگین رشته به ازای مقادیر value به مقدار 1629.73 و با key ها شامل مقدار 1725.29 می باشد.